

2 Теоретические задачи

2.1 Bias-variance-noise decomposition

Пусть $y = f(x) + \epsilon$, где ϵ - шум, независимый от x , $E\epsilon = 0$, $D\epsilon = \sigma^2 = E(y - f(x))^2$, $f(x) = E(y|x)$. Хотим по выборке X получить функцию $a_X(x) = f(x)$. Найдем матожидание ошибки (MSE), т.е. $E(y - a_X(x))^2$.

$$\begin{aligned} E((y - a_X(x))^2|x) &= \\ &= E(E(f(x) - \epsilon - a_X(x))^2|x) = \\ &= E((a_X(x) - f(x))^2 - 2 \cdot \epsilon \cdot (a_X(x) - f(x)) + \epsilon^2|x) = \\ &= E((a_X(x) - f(x))^2|x) - 2 \cdot E(\epsilon) \cdot (a_X(x) - f(x)) + E(\epsilon^2) = \\ &= E((a_X(x) - f(x))^2|x) + \sigma^2 = \\ &= E((a_X(x) - f(x) + (Ea_X(x) - Ea_X(x)))^2|x) + \sigma^2 = \\ &= E((a_X(x) - Ea_X(x))^2 + (f(x) - Ea_X(x))^2 - \\ &\quad - 2 \cdot (a_X(x) - Ea_X(x)) \cdot (f(x) - Ea_X(x))|x) + \sigma^2 = \\ &= (a_X(x) - Ea_X(x))^2 + (f(x) - Ea_X(x))^2 + \sigma^2 = \\ &= (a_X(x) - Ea_X(x))^2 + (E(y|x) - Ea_X(x))^2 + E(y - E(y|x))^2 \end{aligned}$$

$$\begin{aligned} E(y - a_X(x))^2 &= E(E(y - a_X(x))^2|x) = \\ &= E(a_X(x) - Ea_X(x))^2 + E(E(y|x) - Ea_X(x))^2 + E(y - E(y|x))^2 = \\ &= \text{variance} + \text{bias} + \text{noise} \end{aligned}$$

2.2 Смещение и разброс в бэггинге

Для композиции с одинаковыми параметрами: пусть $a_m(x)$ - ответ m -го алгоритма на объекте x . В предположении, что a_m - одинаково распределены, $m \in \overline{1, M}$.

$$a(x) = \frac{1}{M} \sum_{m=1}^M a_m(x)$$

$$E_{X,Y,x,y}(a(x)) = \frac{1}{M} \sum_{m=1}^M E_{X,Y,x,y}(a_m(x)) = E_{X,Y,x,y}(a_1(x))$$

Поэтому bias не изменится от использования беггинга.

$$\begin{aligned} D_{X,Y,x,y}(a(x)) &= \frac{1}{M^2} D \left(\sum_{m=1}^M a_m(x) \right) = \\ &= \frac{1}{M^2} \left(M \cdot D(a_1(x)) + \sum_{i \neq j} \text{cov}(a_i(x), a_j(x)) \right) \end{aligned}$$

Если коэффициент корреляции одинаковый (а раз параметры совпадают, это логично) и равен ρ .

$$\begin{aligned} D_{X,Y,x,y}(a(x)) &= \frac{1}{M^2} (M \cdot D(a_1(x)) + M \cdot (M - 1) \cdot \rho \cdot D(a_1(x))) = \\ &= \left(\rho + \frac{1 - \rho}{M} \right) \cdot D(a_1(x)) \end{aligned}$$

Поэтому чем меньше ρ , тем меньше variance.

2.3 Корреляция ответов базовых алгоритмов

Пусть X_1, X_2, \dots, X_M - одинаково распределенные случайные величины с дисперсией σ^2 , любые две из которых имеют положительную корреляцию ρ . Посчитаем дисперсию их среднего.

$$\begin{aligned} D\left(\frac{\sum_{i=1}^M X_i}{M}\right) &= \frac{1}{M^2} \cdot cov\left(\sum_{i=1}^M X_i, \sum_{i=1}^M X_i\right) = \\ &= \frac{1}{M^2} \left(\sum_{i=1}^M D(X_i) + \sum_{i \neq j} cov(X_i, X_j) \right) = \\ &= \frac{1}{M^2} (M \cdot \sigma^2 + M \cdot (M - 1) \cdot \rho \cdot \sigma^2) = \\ &= \frac{\sigma^2}{M} + \frac{M - 1}{M} \cdot \rho \cdot \sigma^2 = \\ &= \rho \cdot \sigma^2 + \frac{1 - \rho}{M} \cdot \sigma^2 \end{aligned}$$